

Общие правила: N – размер объединенной выборки, m – размер выборки X (первой), n – размер выборки Y (второй), s_x – несмещенная (исправленная) дисперсия, \widehat{d}_x – смещенная (обычная) выборочная дисперсия. R_i – ранг элемента (ранг – это номер элемента (нумерация с 1) в объединенной выборке. При этом если есть несколько одинаковых элементов (связка), то у них один ранг, равный среднему арифметическому их номеров). l – число связок, t_k – длина k -ой связки. Гипотезы H_1, H_2, H_3 – альтернативные, выбирается одна. Ранговые критерии сводятся к нормальному $(X - EX) / \sqrt{DX}$

Меры Гутмана: $p_1 = 1 - \frac{\max_B}{n}, p_2 = 1 - \frac{\sum \max_B}{n}, \lambda_B = \frac{p_1 - p_2}{p_1}$, (сумма по local max)

Проверка гипотез о сдвиге («изменении мат. ожидания»)

$$H_0: \theta = 0$$

$$H_1: \theta < 0 \text{ (уменьшилось)}, H_2: \theta > 0 \text{ (увеличилось)}, H_3: \theta \neq 0 \text{ (изменилось)}$$

$$(\text{Дополнительно: } F_y = F_x(t - \theta), \theta = EY - EX)$$

$$\begin{aligned} & \bar{\sigma} < 0: (-\infty; Z_\alpha) \\ & > 0: (Z_{1-\alpha}; +\infty) \\ & \neq 0: \left(-\infty; Z_{\frac{\alpha}{2}}\right) \\ & \cup \left(Z_{1-\frac{\alpha}{2}}; +\infty\right) \end{aligned}$$

Критерий Стьюдента (нормальное распределение)

$$T = \frac{\bar{Y} - \bar{X}}{S_{xy} \sqrt{\frac{1}{n} + \frac{1}{m}}} \sim t(n + m - 2)$$

$$S_{xy} = \sqrt{\frac{(m-1) \cdot s_x^2 + (n-1) \cdot s_y^2}{n + m - 2}}$$

Условие: равенство теоретических дисперсий

Критерий Вилкоксона (неизвестное распределение)

$$W_{m,n} = \sum_{j=1}^n R_j \text{ (ранги второй выборки)}$$

$$E(W_{m,n}) = \frac{n}{2}(N + 1)$$

$$D(W_{m,n}) = \frac{m \cdot n}{12}(N + 1) \text{ (без связок)}$$

$$D_{\text{св}}(W_{m,n}) = D(W_{m,n}) - \frac{m \cdot n \sum_{k=1}^l (t_k(t_k^2 - 1))}{12N(N - 1)}$$

Проверка сжатия («изменения дисперсии»)

$$H_0: \Delta = \frac{\sigma_y}{\sigma_x} = 1$$

Критерий Фишера (нормальное распределение)

$$T = \frac{S_Y^2}{S_X^2} \sim F(n - 1, m - 1) \text{ (если } S_Y > S_X)$$

(если нет, то числитель из знаменатель меняются местами, $n - 1$ и $m - 1$ тоже меняются)

$$\bar{G}: (\text{ОСОБЫЕ}) (f_{1-\alpha}; +\infty) \text{ (если } H_1 > 1 | < 1) \text{ или } (f_{1-\frac{\alpha}{2}}; +\infty) \text{ (если } H_1 \neq 1)$$

Критерий Ансари-Брэдли (неизвестное распределение)

$$A_{m,n} = \sum_{i=1}^m q_i = \begin{cases} R_i, & \text{если } R_i \leq \frac{N + 1}{2} \\ N + 1 - R_i, & \text{иначе} \end{cases}$$

$$E(A_{m,n}) = \begin{cases} \frac{m \cdot (N+2)}{4}, & N = 2k \\ \frac{m \cdot (N+1)^2}{4N}, & N = 2k + 1 \end{cases}$$

$$D(A_{m,n}) = \begin{cases} \frac{m \cdot n \cdot (N+2) \cdot (N-2)}{48(N-1)}, & N = 2k \\ \frac{m \cdot n \cdot (N^2+3)(N+1)}{48N^2}, & N = 2k + 1 \end{cases}$$

$$D(A_{m,n}) = \begin{cases} \frac{mn(16 \sum_{j=1}^k t_j R_j^2 - N(N+2)^2)}{16N(N-1)}, & N = 2k \\ \frac{mn(16 \sum_{j=1}^k t_j R_j^2 - (N+1)^4)}{16N^2(N-1)}, & N = 2k + 1 \end{cases}$$

Критерий Колмогорова-Смиронова (проверка соответствия распределений)

$$D_{m,n} = \sup |\widehat{F}_X(t) - \widehat{F}_Y(t)|$$

$$D^*_{m,n} = \sqrt{\frac{nm}{n+m}} D_{m,n} \sim K \text{ (Колмогорова)}$$

$$H_0: \forall t F_X(t) = F_Y(t) \quad H_1: \exists t F_X(t) \neq F_Y(t)$$

Однофакторный дисперсионный анализ. (Проверяет несколько выборок). Модель: $X_{ij} = \theta + \tau_j + \varepsilon_{ij}$. j – номер выборки, i – номер элемента, τ_j – отклонение от общего среднего, ε_{ij} – независимые ненаблюдаемые погрешности, k – число выборок. $H_0: \tau_1 = \dots = \tau_k = 0$ $H_1: \exists j \tau_j \neq 0$. $\bar{X}_{\cdot j}$ – среднее по выборке j , \bar{X}_N – среднее по общей выборке.

Классический F- критерий (норм. распред. с один. дисп.) $T(Z_N) = \frac{\frac{1}{k-1} \sum_{j=1}^k n_j (\bar{X}_{\cdot j} - \bar{X}_N)^2}{\frac{1}{N-k} \sum_{j=1}^k \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{\cdot j})^2} \sim F(k - 1, N - k)$

Критическая область: $(f_{1-\alpha}(k - 1; N - k); +\infty)$ \tilde{S}_N^2

Доверительный интервал $\theta_j = \theta + \tau_j$: $\theta_j \in \left[\bar{X}_{.j} \pm \frac{1}{\sqrt{n_j}} \sqrt{\tilde{S}_N^2} t_{1-\frac{\alpha}{2}, N-k} \right]$ // Доверительный интервал контраста: $\gamma =$		
$\sum_{j=1}^k c_j \theta_j$, где $\sum_{j=1}^k c_j = 0$ $\gamma \in \left[\sum_{j=1}^k c_j \bar{X}_{.j} \pm t_{1-\frac{\alpha}{2}, N-k} \sqrt{\tilde{S}_N^2 \sum_{j=1}^k \frac{c_j^2}{n_j}} \right]$	Критерий Краскела-Уолиса (любое распредел.) $H_0: \theta_1 = \dots = \theta_k = \theta$ $H_1: \exists i \neq j \theta_i \neq \theta_j$ Крит. Обл. правая $H = \frac{12}{N(N+1)} \sum_{j=1}^k \frac{1}{n_j} \left(\sum_{i=1}^{n_j} R_{ij} \right)^2 - 3(N+1) \sim \chi^2(k-1)$ $H' = \frac{H}{1 - \frac{1}{(N^3 - N)} \sum_{i=1}^l (t_i^3 - t_i)}$ (связки)	
Критерий Джонкхиера (любое распредел.) $H_a: \theta_1 \leq \dots \leq \theta_k$ $\phi(y, z) = 1 (y < z), 0.5 (y = z), 0 (y > z)$. $J = \sum_{1 \leq l < m \leq k} U_{lm}$ $U_{lm} = \sum_{i=1}^{n_l} \sum_{j=1}^{n_m} \phi(X_{il}, X_{jm})$ $E(J) = \frac{1}{4} (N^2 - \sum_{j=1}^k n_j^2)$ $D(J) = \frac{1}{72} (N^2 (2N+3) - \sum_{j=1}^k n_j^2 (2n_j+3))$ Крит. область правая	Проверка независимости номинальных признаков	Критическая область правая m, k – размеры ↓
Теорема Фишера-Пирсона $H_0: \forall i, j p_{ij} = p_{.i} p_{.j}$ $H_a: \exists i, j p_{ij} \neq p_{.i} p_{.j}$ $\hat{\chi}^2 = n \sum_{i=1}^m \sum_{j=1}^k \left(\frac{n_{ij}^2}{n_{i.} n_{.j}} - 1 \right)$ Для $m = k = 2$ формула: $\hat{\chi}^2 = \frac{n(n_{11}n_{22} - n_{12}n_{21})^2}{n_{1.}n_{2.}n_{.1}n_{.2}}$. Коэффициент контингенции (двухстор. связь) $\Phi = \frac{ad-bc}{\sqrt{(a+b)(d+c)(a+c)(b+d)}}$, ассоциации Юла ($A \Rightarrow B$, если $Q = 1$) $Q = \frac{ad-bc}{ad+bc}$, взаим. связи Пирсона: $P = \sqrt{\frac{\hat{\chi}^2}{\hat{\chi}^2 + n}}$, Крамера $C = \sqrt{\frac{\hat{\chi}^2}{n \cdot \min\{(m-1), (k-1)\}}}$ $\hat{\chi}^2 \sim \chi^2((k-1)(m-1))$		
Критерии проверки связи двумерных выборок: $(X_1, Y_1) \dots (X_n, Y_n)$. Коэффициент ранговой корреляции Спирмена: $\hat{\rho}_S = 1 - 6 \cdot \frac{\sum_{i=1}^n (R_i - S_i)^2}{n^3 - n}$, если связи: $\hat{\rho}_S = 1 - \frac{\sum_{i=1}^n (R_i - S_i)^2}{\frac{1}{6}(n^3 - n) - (u_1 + u_2)}$ $\sqrt{n-1} \cdot \hat{\rho}_S \sim N(0,1)$, где $u_1 = \frac{1}{12} \sum_{k=1}^q (u_{1k}^3 - u_{1k})$, u_{1k} – размер k -ой связи, q – количество связей, для u_2 выборки Y ситуация симметрична, согласованности Кендалла $\hat{\tau}_{XY} = 1 - \frac{4K}{n(n-1)}$, где K – количество пар, где $i < j$ и $\text{sign}\{(X_i - X_j)(Y - Y_i)\} = -1$. $\frac{3\sqrt{n}\hat{\tau}_{XY}}{2} \sim N(0,1)$. $H_a: \rho > 0, \rho < 0, \rho \neq 0$		
Кр. осн. на выбор. коэфф. корр. (норм. распредел.) (H_a совпадает с пред.) $\hat{\rho}_{XY} = \frac{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{S_X S_Y} \frac{\sqrt{n-2} \hat{\rho}_{XY}}{\sqrt{1 - \hat{\rho}_{XY}^2}} \sim t(n-2)$ ДИ: (обыч. норм) $\hat{\rho}_{XY} \in \left[\hat{\rho}_{XY} \left(1 - \frac{1 - \hat{\rho}_{XY}^2}{2n} \right) \pm Z_{1-\frac{\alpha}{2}} \frac{(1 - \hat{\rho}_{XY}^2)^{3/2}}{n} \right]$, преобр. Фишера: $[z_1, z_2] = \left[\frac{1}{2} \ln \left(\frac{1 + \hat{\rho}_{XY}}{1 - \hat{\rho}_{XY}} \right) - \frac{\hat{\rho}_{XY}}{2(n-1)} \pm \frac{Z_{1-\frac{\alpha}{2}}}{\sqrt{n-3}} \right]$, $\hat{\rho}_{XY} \in [th z_1, th z_2]$, $th x = \frac{e^x - e^{-x}}{e^x + e^{-x}}$; $\hat{\rho}_{xy} = \frac{\frac{1}{n} \sum X_i Y_i - \bar{X} \bar{Y}}{\sqrt{(\frac{1}{n} \sum X_i^2 - (\bar{X})^2)(\frac{1}{n} \sum Y_i^2 - (\bar{Y})^2)}}$ Частный коэффициент корреляции (норм. распредел.). Убирает влияние других факторов.		
$\rho_{12;3,\dots,l} = \frac{-R_{12}}{\sqrt{R_{11}R_{22}}}$, где l – число элементов, $R_{ij} = (-1)^{i+j} M_{ij}$, $M_{ij} = \det M$ без i, j . Для $l = 3$, $\rho_{12;3} = \frac{\rho_{12} - \rho_{13}\rho_{23}}{\sqrt{(1 - \rho_{13}^2)(1 - \rho_{23}^2)}}$. При использ. критер. выше $\frac{\sqrt{n-d-2} \hat{\rho}_{XY}}{\sqrt{1 - \hat{\rho}_{XY}^2}} \sim t(n-d-2)$. d – число зафиксированных (после ;		Коэфф. конкордации Кендалла (независ. нескол.)
$\hat{W}_n(m) = \frac{12}{m^2(n^3-n)} \sum_{i=1}^n \left(\sum_{j=1}^m R_{ij} - \frac{m(n+1)}{2} \right)^2$; $m(n-1)\hat{W}_n(m) \sim \chi^2(n-1)$ m – число ранжировок, n – длина выборки. (крит. обл. правая) $H_0: F_{\xi}(x_1, \dots, x_m) = F_{\xi_1}(x_1) \cdot \dots \cdot F_{\xi_m}(x_m)$, $H_a \neq$. крит. нужен для проверки независ. ранж. выборок.		
Линейная регрессия. $Y = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p + \varepsilon$; $\hat{\beta} = (X^T X)^{-1} X^T Y$, $\hat{\beta}$ – вектор коэфф., X – матр. перв. столбец 1, другие – значения X_{ip} , p – кол-во регрессоров (X). $TSS = \sum_{i=1}^n (Y_i - \bar{Y})^2 = ESS + RSS$; $RSS = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$; $ESS = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2$. $\sigma_{\varepsilon}^2 = \frac{RSS}{n-p-1}$. $\sigma_{\hat{\beta}_i} = \sqrt{\sigma_{\varepsilon}^2 C_{ii}}$, где C_{ii} – элемент ii матрицы $(X^T X)^{-1}$. <u>F-тест (знач. всей регресс)</u> $\hat{F} = \frac{\frac{ESS}{p}}{\frac{RSS}{n-p-1}} \sim F(p, n-p-1)$ ($H_0 \forall \beta = 0$, $H_a \exists \neq 0$). <u>T-тест (знач. 1 факт.)</u> ($H_0: \beta_i = 0$, $H_a \neq$) $\frac{\hat{\beta}_i - \beta_i}{\sigma_{\hat{\beta}_i}} \sim t(n-p-1)$ (можно пров. не только = 0, если просят). Коэфф. детерминации. (насколько хороша регресс.) $R^2 = \frac{ESS}{TSS} = 1 - \frac{RSS}{TSS}$, $\widehat{R}_{кор.}^2 = 1 - (1 - \widehat{R}^2) \frac{n-1}{n-p-1}$. <u>Тест Чоу</u> (пр. что две модели совпадают) $H_0: \beta_0^{(1)} = \beta_0^{(2)}; \dots; \beta_p^{(1)} = \beta_p^{(2)}$, $H_a: \exists \neq$. Крит. Обл. правая. $\frac{RSS_{общ} - RSS_1 - RSS_2}{\frac{p+1}{N-2p-2}} \sim F(p+1, N-2p-2)$. ДИ для $E[Y X_0]$: $\left(\hat{Y}(X_0) \pm t_{1-\frac{\alpha}{2}, n-2} \sigma_{\varepsilon} \sqrt{\frac{1}{n} + \frac{(X_0 - \bar{X})^2}{\sum_{l=1}^n (X_l - \bar{X})^2}} \right)$, для $Y(X_0)$ (+1 под		
корень), для $\sigma_{\varepsilon} \frac{RSS}{\sigma_{\varepsilon}} \sim \chi^2(n-p-1)$. <u>Тест на огранич.</u> $H_0: \widehat{\beta}_{q+1} = \dots = \widehat{\beta}_p = 0 (q < p)$, $H_a: \exists \neq$ $\frac{RSS_{урез}^2 - RSS_{полн}^2}{\frac{p-q}{n-p-1} RSS_{полн}^2} \sim F(p-q, n-p-1)$ $F(p-q, n-p-1)$. Крит. обл. правая. <u>Оценки МНК</u> : $(Y = a + e; \hat{a} = \bar{Y})$ ($Y = bX_i + e; \hat{b} = \frac{\sum X_i Y_i}{\sum X_i}$) ($Y = a + bX_i + e$) ($\hat{a} = \bar{Y} - \hat{b} \bar{X}$ $\hat{b} = \sum (X_i - \bar{X})(Y_i - \bar{Y}) / \sum (X_i - \bar{X})^2$). $\sigma_a^2 = \sigma_{\varepsilon}^2 (1/n + \bar{X}^2 / \sum (X_i - \bar{X})^2)$, $\sigma_b^2 = \sigma_{\varepsilon}^2 / \sum (X_i - \bar{X})^2$, ($Y = a + bX + e$) HELP		